

试工文档：受损语音转录修复 Agent 项目

1. 项目目标

本项目旨在针对**受损的语音转录文件（damaged transcript）**进行修复。

输入包括：

- 一段视频
- 一段受损的 transcript

其中，受损 transcript 并不是 Ground Truth，而是一个经过扰动、存在错误、需要进一步修复的中间文本。我们的目标是通过 Agent 框架和多模态能力，对该 transcript 进行修复，输出更接近真实内容的最终转录文本。

随后，我们将：

- 对输入 transcript 与输出 transcript 进行对比
- 使用 Ground Truth 作为标准答案进行评估
- 统计最终修复准确率

2. 总体方法

我们计划搭建 **一种 Agent 框架** 来完成受损 transcript 修复任务，并在统一实验设置下验证其效果。

该框架将基于统一配置文件运行，并调用相同的外部能力，包括：

- Whisper
- RAG
- Vision-only 理解模型

项目核心思路是结合三种模态或信息来源来修复 transcript：

- 音频信息：通过 Whisper 获取语音识别线索
- 视觉信息：通过 vision-only model 获取画面中的辅助理解线索
- 外部知识/上下文信息：通过 RAG 提供补充语义支持

其中，RAG 不只是通用检索模块，还需要围绕视频主题和说话人背景建立配套语料，以帮助模型识别领域术语、主题词汇和上下文表达。

3. 数据构造与合成方案

3.1 原始数据收集

首先收集 **10 段时长约 1 分钟的 YouTube 视频 source** 作为原始实验数据。

这些视频不应彼此完全无关，而应尽量**围绕同一个主题或同一个核心人物展开**，以便形成更稳定的上下文和可检索知识空间。

例如，可以围绕某一位人物收集其不同场景下的视频：

- 演讲

- 上课
- 采访
- 社交活动

这样可以让数据同时覆盖不同说话风格、场景和表达方式，但又保持主题连续性，便于后续 RAG 补充和 transcript 修复。

视频类型可以覆盖不同场景，包括但不限于：

- multi-talker
- single-talker
- 独白
- speech

在视频收集阶段，还需要同步整理与该人物或主题相关的文档材料，作为 RAG 的补充语料来源。例如：

- 演讲主题相关的讲义
- 课程资料
- 采访背景材料
- 公开文章、简介或活动介绍
- 与主题相关的术语表或参考文本

如果某段视频围绕一个明确主题展开，那么我们还可以额外寻找该主题下的其他讲义或文本材料，用来补充 RAG 词汇库，增强模型对专有词汇、主题术语和上下文表达的理解能力。

3.2 RAG 语料收集原则

为了提升 transcript 修复质量，RAG 语料的收集应与视频 source 保持强相关。建议原则包括：

- 与视频中的人物、主题或活动直接相关
- 能补充专有名词、术语、演讲主题和背景知识
- 尽量来自公开、可追溯的文本材料
- 在不同视频之间保持主题连续性，避免知识源过于分散

RAG 的价值主要体现在以下几方面：

- 帮助修复专有名词识别错误
- 帮助补足被删减或识别错误的主题词汇
- 帮助在上下文中判断更合理的词语替换
- 为多轮 Agent 推理提供可检索证据

3.3 Ground Truth 与受损 transcript 构造

对于每段视频，我们先获取 YouTube 上的原始转录文本，再基于该文本人工加噪，构造受损 transcript。

加噪方式包括：

- 多词：加入额外词语
- 少词：删除部分词语
- 改词：替换为错误词语
- 同音词替换

- 同一类词替换或近似词替换

同时，噪声设置按照 **3 种难度梯度** 进行分层。也就是说，每个视频 source 都会对应 3 个不同难度的 damaged transcript 版本，用于测试该 Agent 框架在不同受损程度下的表现。

因此，数据规模定义如下：

- 原始视频 source 数量：10 段
- 每段视频对应 3 种难度梯度
- 总实验样本数：30 段

4. 实验流程

整体流程如下：

1. 收集 10 段 YouTube 视频素材
2. 获取对应 transcript
3. 人工加噪，生成 damaged transcript
4. 将视频和 damaged transcript 输入 Agent 框架
5. 调用 Whisper、RAG、Vision-only model 进行修复
6. 输出修复后的 transcript
7. 与 Ground Truth 对比，计算准确率
8. 分析该 Agent 框架在不同样本和不同难度下的修复效果

5. Agent 实验设置

为了保证实验结果稳定、可复现，Agent 框架应尽量保持一致的实验条件：

- 使用同一批视频数据
- 使用同一批 damaged transcript
- 使用同一个 configuration 文件
- configuration 文件中统一定义 Whisper、Vision-only model、RAG 的 API 调用方式

这样可以将分析重点集中在 Agent 的组织方式、多模态调用链路以及最终修复效果上。

6. 评估指标

最终评估需要围绕 Ground Truth 展开，重点包括：

- 输入 damaged transcript 与 Ground Truth 的差距
- 输出 repaired transcript 与 Ground Truth 的差距
- 修复前后准确率提升幅度
- 该 Agent 框架在不同难度样本上的性能表现

后续可进一步明确具体评价指标，例如：

- Word Accuracy
- Word Error Rate (WER)
- Character Error Rate (CER)
- 修复增益 (relative improvement)

7. 协作方式

本项目总共由 **6 人协作** 完成，协作方式如下：

- 使用 GitHub 作为中间资源交换场所
- 所有成员围绕统一配置文件和统一实验任务展开协作

建议分工如下：

7.1 数据收集负责人

第 1 人负责：

- 数据收集
- 视频 source 筛选
- transcript 获取

7.2 数据合成负责人

第 2 人负责：

- Ground Truth 整理
- damaged transcript 构造
- 噪声注入与难度分层

7.3 Agent 框架负责人

第 3 人负责：

- Agent 主流程设计与实现
- Whisper、Vision-only model、RAG 的接口接入
- 实验运行与基础结果导出

统一使用同一个 configuration 文件，文件内管理：

- Whisper API
- Vision-only model API
- RAG API

7.4 PPT 负责人

第 4 人负责：

- 整理 methodology
- 整理 result analysis
- 撰写与制作 PPT

7.5 Presentation 负责人

第 5 人负责：

- 口头讲解

- demo 展示
- 最终 presentation 出镜或录屏讲述

7.6 剪辑负责人

第 6 人负责：

- presentation 视频剪辑
- 素材拼接与字幕整理
- 最终成片导出

最终 presentation 形式为**本地录视频展示**。

8. 最终交付内容

项目最终需要完成的内容包括：

- 10 段实验视频 source 及其 Ground Truth 数据
- 基于 3 种难度梯度构造的 30 组 damaged transcript / 修复任务样本
- 单一 Agent 框架的实现与测试结果
- 统一的准确率统计结果
- 不同难度样本下的结果分析
- 最终 presentation 视频

9. 当前已确认的关键信息

- 任务主题：受损语音转录修复
- 输入：视频 + damaged transcript
- 输出：修复后的 transcript
- 能力模块：Whisper + RAG + Vision-only model
- Agent 框架：单一 Agent 方案
- 数据规模：10 段约 1 分钟 YouTube 视频 source，按 3 种难度梯度扩展为 30 个实验样本
- 协作人数：6 人
- 协作平台：GitHub
- 最终展示：本地录屏 presentation

10. 后续待补充内容

后续建议补充以下内容，以便形成更正式的项目文档：

- configuration 文件的具体字段设计
- damaged transcript 的噪声注入规范
- 准确率计算公式与评估脚本
- Agent 的 prompt / tool 调用流程图
- result analysis 的展示模板
- presentation 的时间分配与脚本安排