

TED AI 数据集收集工作总结

一、工作职责说明

本次项目是一个受损语音转录修复 Agent 项目，整体目标是输入视频和受损 transcript，通过 Whisper、RAG、Vision-only model 和 Agent 框架对 transcript 进行修复，并使用 Ground Truth 进行评估。

我在本项目中主要负责数据收集部分，具体工作包括：

1. 筛选合适的视频 source；
2. 下载并截取视频片段；
3. 提取对应音频；
4. 获取并整理 Ground Truth transcript；
5. 创建 metadata 表格；
6. 整理 RAG 背景资料；
7. 将数据上传到 GitHub 仓库，方便组员继续使用。

最终整理的数据主要存放在 GitHub 仓库的 `data/` 文件夹中。

二、数据来源说明

项目最初计划使用 YouTube 视频作为 source，但在实际操作中，YouTube 下载过程多次触发机器人验证和 Cookie 认证问题，导致下载不稳定。为了保证数据收集可以顺利完成，我最终选择使用 TED 和 TED-Ed 的公开视频作为数据来源。

选择 TED / TED-Ed 的原因包括：

1. 视频公开，访问较稳定；
2. 大部分视频自带官方 transcript；
3. 视频主题专业，适合人工智能和机器学习相关项目；
4. 视频质量较高，声音清晰；
5. 适合截取约 1 分钟左右的实验片段。

本次数据集主题主要围绕：

- 人工智能；
- 机器学习；
- 深度学习；
- AI Agent；
- AI 与虚假信息；
- AI 是否真正理解语言；
- 人机融合与 AI 发展。

这样可以保证 10 个视频样本之间具有较强的主题连续性，方便后续 RAG 模块补充背景知识。

三、最终数据集结构

最终数据集位于项目仓库的 `data/` 文件夹中，结构如下：

```
data/
├── videos/
├── audio/
├── transcripts_ground_truth/
├── metadata/
├── rag_docs/
└── README.md
```

各文件夹的作用如下。

1. videos/

`videos/` 文件夹中存放截取后的视频片段，文件命名方式为：

```
video_01.mp4
video_02.mp4
...
video_10.mp4
```

每个视频文件对应一个实验样本。视频片段的来源链接、标题、说话人、起止时间等信息记录在 `metadata/videos_metadata.csv` 中。

2. audio/

`audio/` 文件夹中存放从视频片段中提取出的音频文件，文件命名方式为：

```
video_01.wav
video_02.wav
...
video_10.wav
```

音频格式统一为 WAV，采样率为 16000 Hz，单声道 mono，便于后续使用 Whisper 或其他语音识别模型进行转录。

3. transcripts_ground_truth/

`transcripts_ground_truth/` 文件夹中存放每个视频片段对应的 Ground Truth transcript，文件命名方式为：

```
video_01_ground_truth.txt
video_02_ground_truth.txt
```

```
...  
video_10_ground_truth.txt
```

这些文本主要来自 TED / TED-Ed 官方 transcript，并根据实际截取的视频时间段进行整理。后续负责数据合成的组员可以基于这些 Ground Truth transcript 构造 damaged transcript。

4. metadata/

metadata/ 文件夹中包含：

```
videos_metadata.csv
```

这个 CSV 文件记录每个视频样本的基本信息，包括：

- video_id;
- title;
- source_platform;
- url;
- speaker;
- theme;
- start_time;
- end_time;
- language;
- has_transcript;
- local_video_file;
- audio_file;
- ground_truth_file;
- notes。

这个表格相当于整个数据集的索引文件，方便组员快速查找每个样本的来源和本地文件路径。

5. rag_docs/

rag_docs/ 文件夹中存放 RAG 模块需要使用的背景资料，主要包括：

```
rag_ai_terms.txt  
rag_speaker_background.txt  
rag_video_topics.txt  
rag_dataset_source_notes.txt
```

这些文档分别整理了人工智能相关术语、视频中出现的说话人背景、每个视频的主题简介，以及数据来源说明。它们可以帮助后续 Agent 在修复受损 transcript 时识别专有名词、主题词汇和上下文表达。

四、视频与音频提取流程

本次视频和音频处理主要使用两个工具：

1. `yt-dlp`：用于下载 TED / TED-Ed 视频；
2. `ffmpeg`：用于截取视频片段和提取音频。

1. 安装 yt-dlp

```
python -m pip install -U yt-dlp
```

2. 安装 ffmpeg

Windows 中可以使用：

```
winget install Gyan.FFmpeg
```

安装完成后，需要关闭并重新打开 VS Code，使终端能够识别 `ffmpeg` 命令。

五、下载完整视频的代码

下载完整 TED / TED-Ed 视频的通用命令如下：

```
yt-dlp -o "data/videos/video_XX_full.mp4" "TED_VIDEO_URL"
```

其中：

- `video_XX_full.mp4` 表示完整视频文件；
- `TED_VIDEO_URL` 表示 TED / TED-Ed 视频链接；
- `XX` 对应视频编号，例如 `01`、`02`、`03`。

示例：

```
yt-dlp -o "data/videos/video_01_full.mp4" "https://www.ted.com/talks/eric_schmidt_the_ai_revolution_is_underhyped"
```

下载完成后，会得到完整视频文件。后续实验不直接使用完整视频，而是从完整视频中截取所需片段。

六、截取视频片段的代码

截取指定时间段视频的通用命令如下：

```
ffmpeg -y -ss START_TIME -i "data/videos/video_XX_full.mp4" -t DURATION -map 0:v:0 -map 0:a:0 -c:v libx264 -c:a aac -b:a 128k -movflags +faststart "data/videos/video_XX.mp4"
```

参数说明：

- `-ss START_TIME`：截取开始时间；
- `-i`：输入完整视频；
- `-t DURATION`：截取时长；
- `-map 0:v:0`：选择视频流；
- `-map 0:a:0`：选择音频流；
- `-c:v libx264`：视频编码格式；
- `-c:a aac`：音频编码格式；
- `-b:a 128k`：音频码率；
- `-movflags +faststart`：优化 MP4 文件，方便在线播放；
- 输出文件为 `data/videos/video_XX.mp4`。

示例一：截取开头到 1 分钟：

```
ffmpeg -y -ss 00:00:00 -i "data/videos/video_01_full.mp4" -t 00:01:00 -map 0:v:0 -map 0:a:0 -c:v libx264 -c:a aac -b:a 128k -movflags +faststart "data/videos/video_01.mp4"
```

示例二：截取 00:59 到 02:10：

```
ffmpeg -y -ss 00:00:59 -i "data/videos/video_05_full.mp4" -t 00:01:11 -map 0:v:0 -map 0:a:0 -c:v libx264 -c:a aac -b:a 128k -movflags +faststart "data/videos/video_05.mp4"
```

示例三：截取 08:10 到 09:25：

```
ffmpeg -y -ss 00:08:10 -i "data/videos/video_08_full.mp4" -t 00:01:15 -map 0:v:0 -map 0:a:0 -c:v libx264 -c:a aac -b:a 128k -movflags +faststart "data/videos/video_08.mp4"
```

七、提取音频的代码

从视频片段中提取音频的通用命令如下：

```
ffmpeg -y -i "data/videos/video_XX.mp4" -vn -acodec pcm_s16le -ar 16000 -ac 1 "data/audio/video_XX.wav"
```

参数说明：

- `-i`：输入视频片段；
- `-vn`：去掉视频，只保留音频；
- `-acodec pcm_s16le`：保存为 WAV PCM 格式；

- `-ar 16000`：采样率设置为 16000 Hz；
- `-ac 1`：转换为单声道；
- 输出文件为 `data/audio/video_XX.wav`。

示例：

```
ffmpeg -y -i "data/videos/video_01.mp4" -vn -acodec pcm_s16le -ar 16000 -ac 1 "data/audio/video_01.wav"
```

这样得到的音频文件可以直接交给 Whisper 或其他语音识别模型使用。

八、Ground Truth Transcript 整理方法

每个视频片段的 Ground Truth transcript 来自 TED / TED-Ed 官方 transcript。

整理步骤如下：

1. 打开对应 TED / TED-Ed 视频页面；
2. 点击 `Read transcript`；
3. 找到视频片段对应的起止时间；
4. 复制该时间段内的 transcript；
5. 保存为对应的 `.txt` 文件。

例如：

```
data/transcripts_ground_truth/video_01_ground_truth.txt
data/transcripts_ground_truth/video_02_ground_truth.txt
...
data/transcripts_ground_truth/video_10_ground_truth.txt
```

Transcript 的内容需要和视频片段时间范围对应，这样后续评估时才能作为可靠的 Ground Truth。

九、Metadata 表格整理

为了方便管理 10 个样本，我创建了：

```
data/metadata/videos_metadata.csv
```

表头如下：

```
video_id,title,source_platform,url,speaker,theme,start_time,end_time,language,has_transcript,local_video_file,audio_file
```

示例记录：

```
video_01,The AI revolution is underhyped,TED,https://www.ted.com/talks/eric_schmidt_the_ai_revolution_is_underhyped,Eric Schmidt and Bilawal Sidhu,Artificial Intelligence,00:00,01:00,English,yes,data/videos/video_01.mp4,data/audio/video_01.wav,data/transcripts_ground_truth/video_01_ground_truth.txt,TED video with official transcript
```

这个 CSV 文件可以让后续组员快速知道每个视频的来源、截取时间、说话人、主题和本地文件路径。

十、RAG 背景资料整理

为了支持后续 RAG 模块，我整理了 `rag_docs` 文件夹。

文件包括：

```
rag_ai_terms.txt
rag_speaker_background.txt
rag_video_topics.txt
rag_dataset_source_notes.txt
```

其中：

- `rag_ai_terms.txt`：整理人工智能、机器学习、深度学习、AI Agent、Chinese Room、Community Notes 等术语；
- `rag_speaker_background.txt`：整理 Andrew Ng、Eric Schmidt、Jeremy Howard、Peter Steinberger 等人物背景；
- `rag_video_topics.txt`：总结每个视频的主题内容；
- `rag_dataset_source_notes.txt`：说明数据来源和数据集用途。

这些资料可以作为后续 Agent 的外部知识库，帮助模型识别领域术语和上下文表达。

十一、GitHub 上传流程

最终数据上传到项目 GitHub 仓库：

```
ML-Project-group4
```

1. 进入本地 GitHub 仓库

```
cd C:\Users\14472\ML-Project-group4
```

2. 将本地数据复制到仓库

```
robocopy C:\Users\14472\ted_ai_dataset\data C:\Users\14472\ML-Project-group4\data /E /XF *_full.mp4
```

其中：

- /E 表示复制所有子文件夹；
- /XF *_full.mp4 表示不复制完整原视频，只复制处理后的数据文件。

3. 查看 Git 状态

```
git status
```

4. 添加数据文件

```
git add data
```

5. 提交修改

```
git commit -m "add TED AI dataset"
```

6. 上传到 GitHub

```
git push
```

如果远程仓库已经有新的修改，则先同步：

```
git pull --rebase origin main  
git push
```

十二、最终交付内容

本次数据收集工作最终交付内容包括：

1. 10 个 TED / TED-Ed AI 相关视频片段；
2. 10 个从视频中提取的 WAV 音频文件；
3. 10 个 Ground Truth transcript 文件；
4. 1 个 metadata CSV 表格；
5. RAG 背景资料文件；
6. data 文件夹说明文档；
7. 已上传至 GitHub 的完整数据目录。

这些内容为后续 damaged transcript 构造、Whisper 识别、RAG 检索和 Agent 修复实验提供了基础数据。

十三、工作总结

本次工作中，我完成了数据收集负责人的主要任务。首先，我围绕人工智能和机器学习主题筛选了 10 个 TED / TED-Ed 视频 source。随后，我使用 `yt-dlp` 下载完整视频，并使用 `ffmpeg` 截取指定时间段，生成统一命名的视频片段。接着，我从每个视频片段中提取 WAV 音频，并从 TED / TED-Ed 官方 transcript 中整理对应的 Ground Truth 文本。

为了方便项目协作，我还创建了 `videos_metadata.csv`，记录每个样本的来源、标题、说话人、主题、时间范围和文件路径。同时，我整理了 RAG 背景资料，包括术语解释、人物背景和视频主题简介。最后，我将数据上传到 GitHub 仓库的 `data/` 文件夹中，方便后续组员继续进行 damaged transcript 构造、Agent 框架实现和最终实验评估。

整体来看，本次数据收集部分已经为项目后续流程提供了完整、清晰、可复用的数据基础。